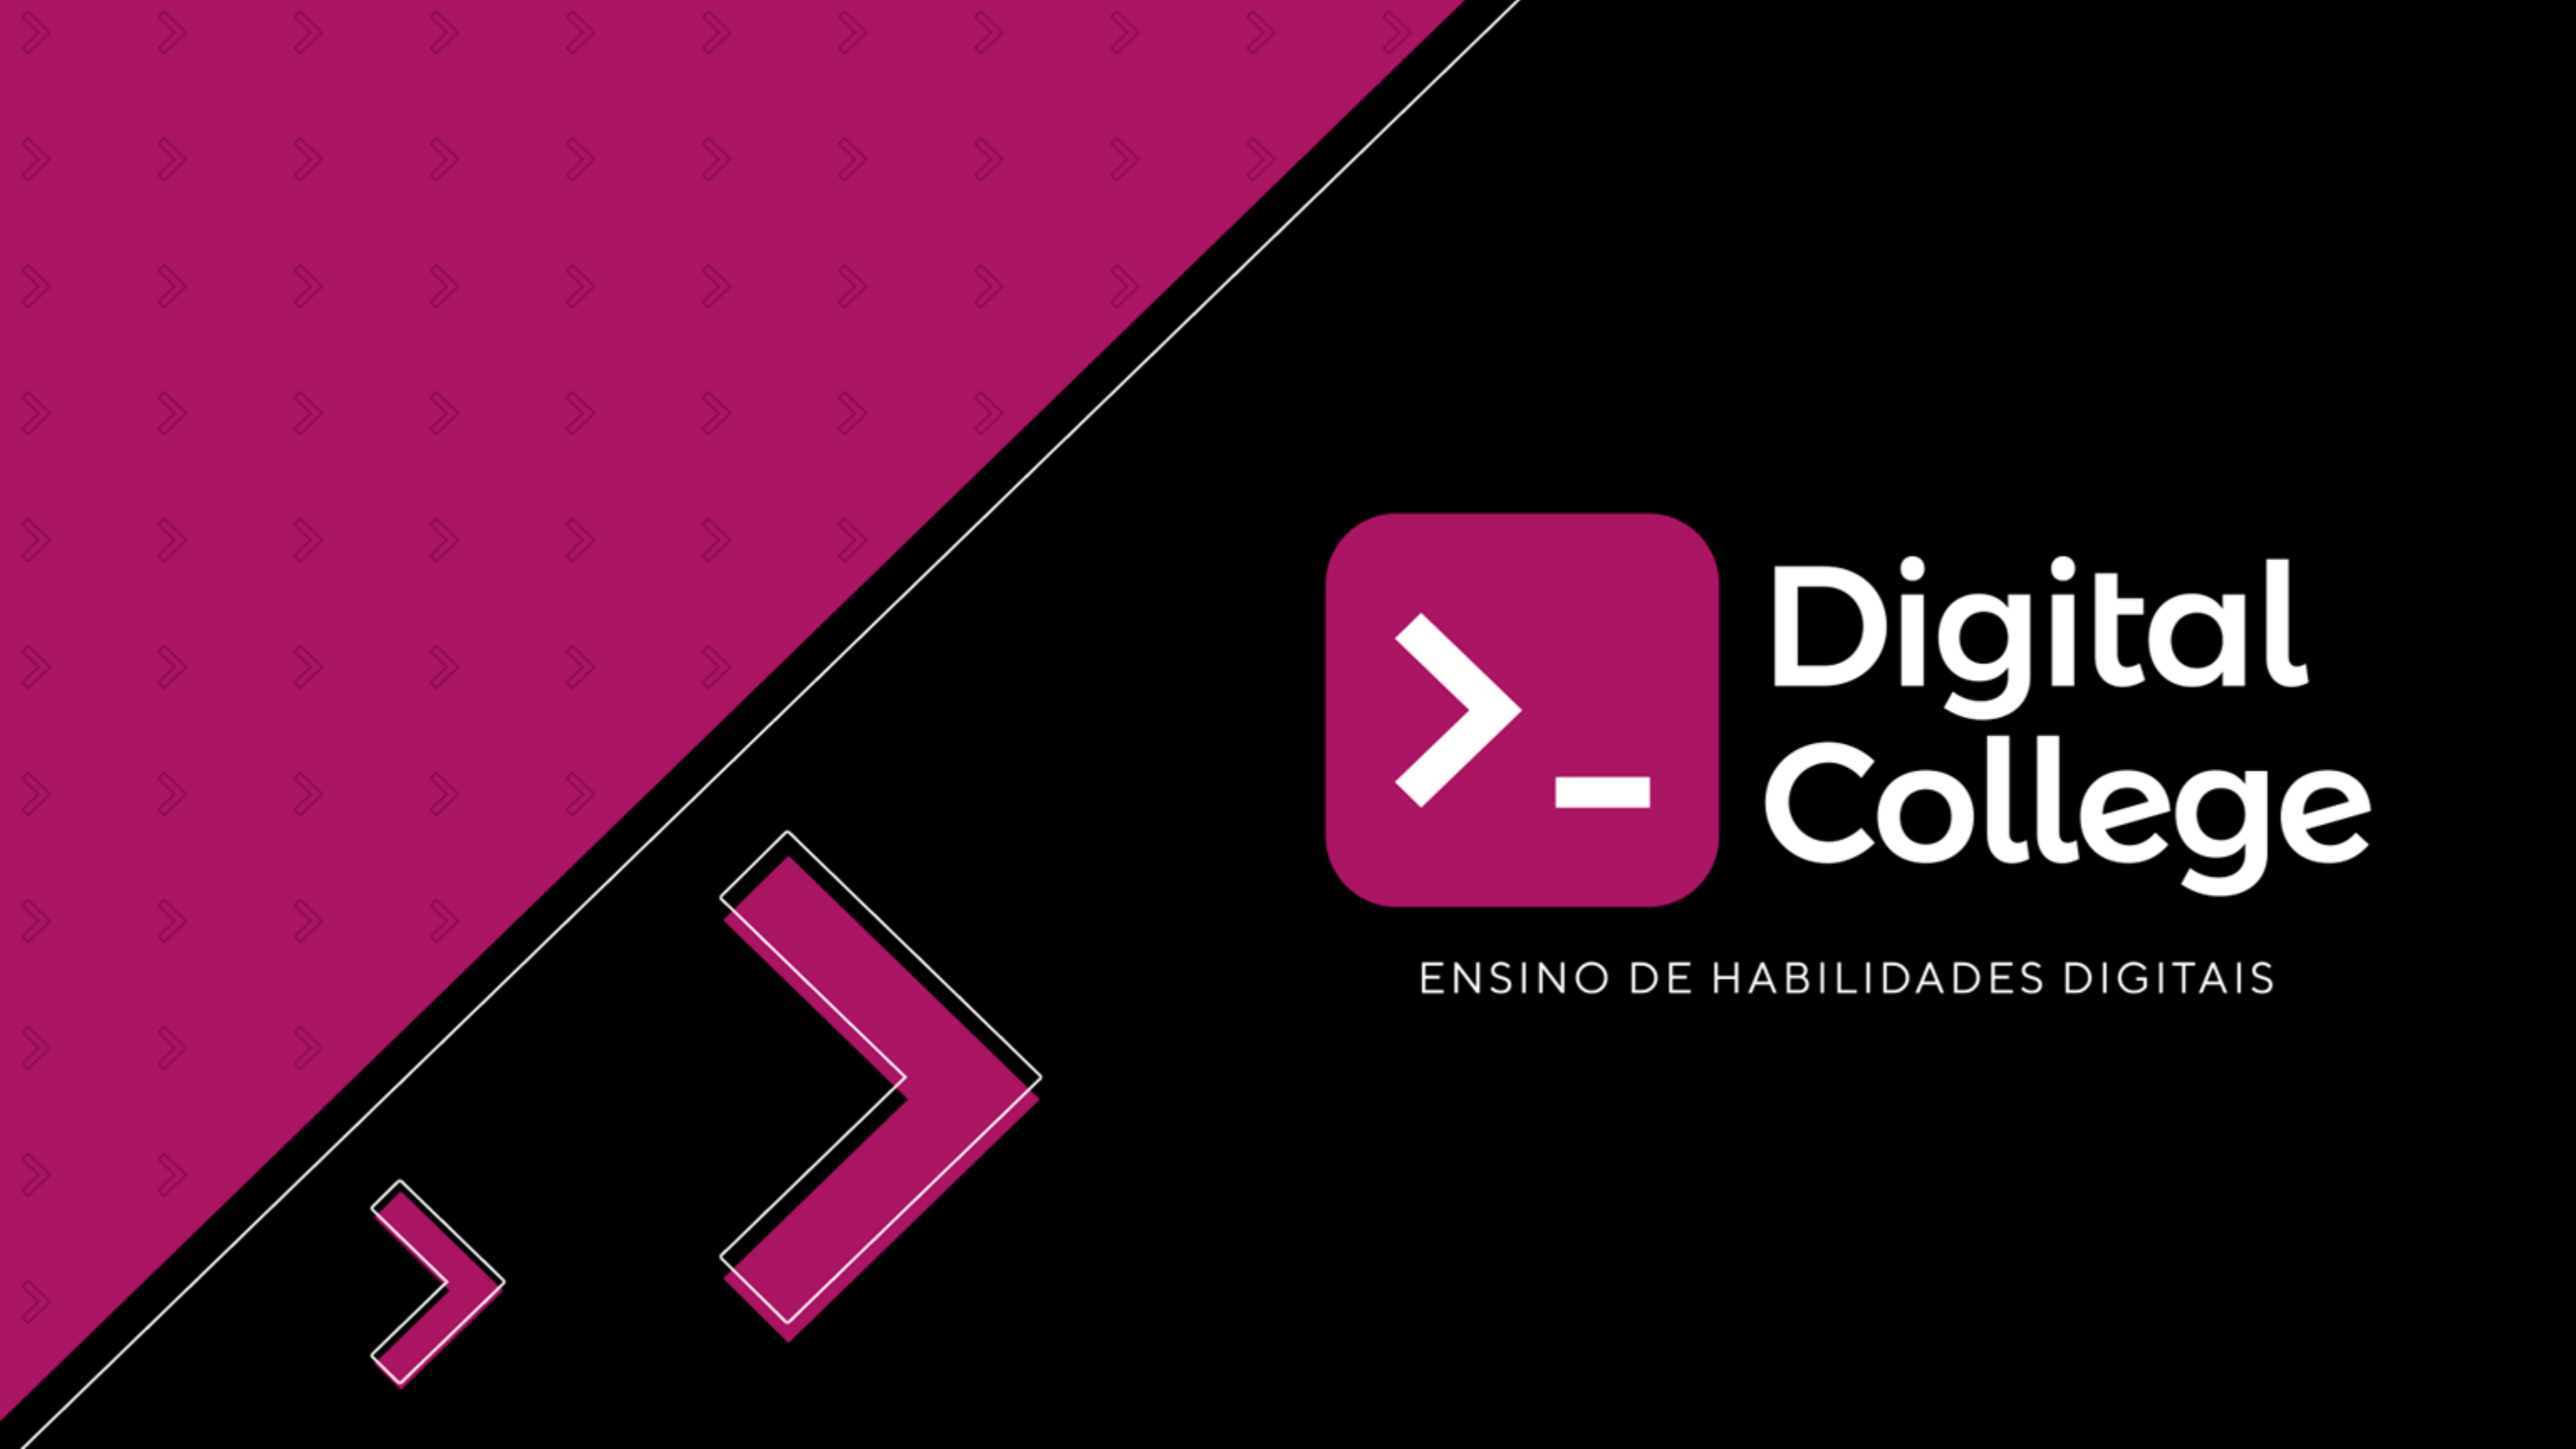
Digital
College
ENSINO DE HABILIDADES DIGITAIS

Digital College

Formação em Data Analytics

Unidade 2 – Módulo 1

Professor: **MSc. Alex Souza**

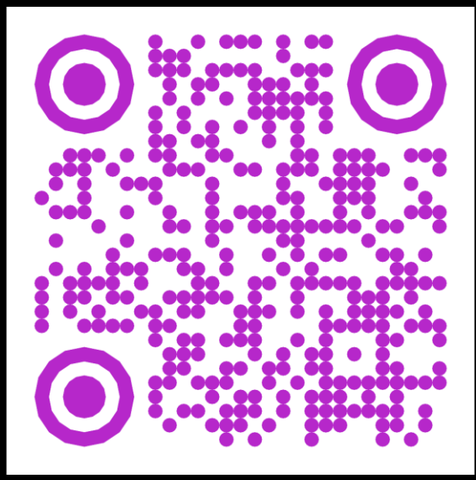

Sobre o curso (Unidades)

Unidade 01 – Banco de Dados
Unidade 02 – ETL
Unidade 03 – Python para Análise de Dados
Unidade 04 – Power BI Desktop

Digital College

Sobre o curso (Unidades e Módulos)

Unidade 02 – Extração, Transformação e Carga - ETL	**1 – Processo de Descoberta de Conhecimento**
	2 – Business Intelligence
	3 – Extração, Transformação e Carga de Dados
	4 – Pipeline de Dados

Digital College

Sobre o curso (Unidades e Módulos)

Unidade 03 – Python para Análise de Dados	1 – Iniciando com Python
	2 – Manipulação de Dados com Python
	3 – Pandas para Análise de Dados
	4 – Gráficos com Python

Digital College

Sobre o curso (Unidades e Módulos)

Unidade 04 – Power BI Desktop	1 – Conhecendo o Power BI
	2 – Modelagem, Relacionamentos e DAX
	3 – Visualização de Dados

Digital College

A Odisseia da Empresa Z em busca de Análises Otimizadas

Livro

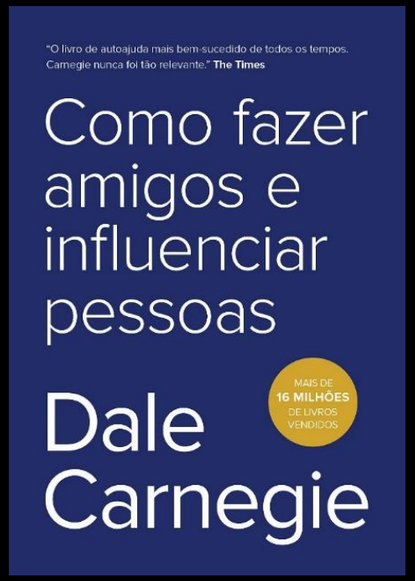
"O livro de autoajuda mais bem-sucedido de todos os tempos. Carnegie nunca foi tão relevante." The Times
Como fazer amigos e influenciar pessoas
MAIS DE 16 MILHÕES DE LIVROS VENDIDOS
Dale Carnegie

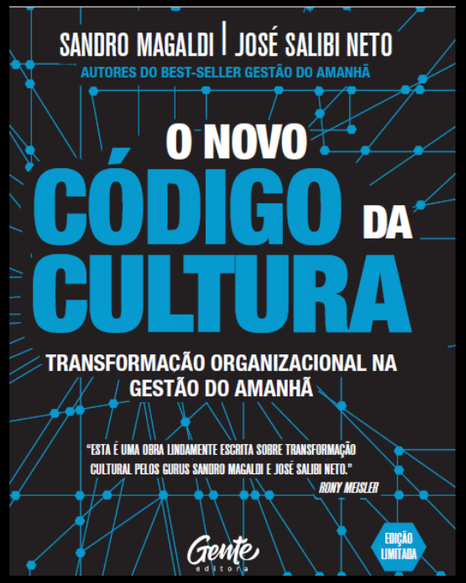
SANDRO MAGALDI | JOSÉ SALIBI NETO
AUTORES DO BEST-SELLER GESTÃO DO AMANHÃ
O NOVO CÓDIGO DA CULTURA
TRANSFORMACÃO ORGANIZACIONAL NA GESTÃO DO AMANHÃ
"ESTA É UMA OBRA LINDAMENTE ESCRITA SOBRE TRANSFORMAÇÃO CULTURAL PELOS GURUS SANDRO MAGALDI E JOSÉ SALIBI NETO."
RONY MEISLER
Gente editora
EDIÇÃO LIMITADA


SCRUM
A arte de fazer o dobro do trabalho na metade do tempo
JEFF SUTHERLAND
Cocriador do Scrum
e J.J. SUTHERLAND

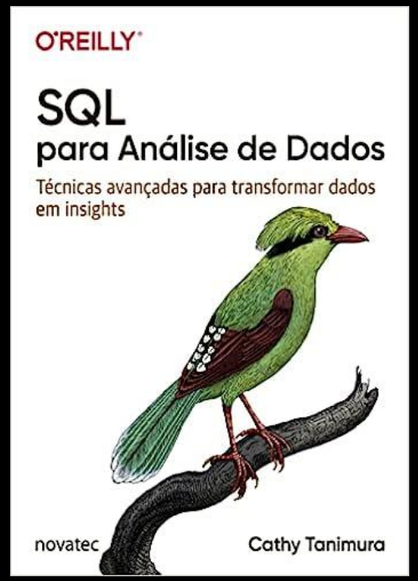
O'REILLY
SQL para Análise de Dados
Técnicas avançadas para transformar dados em insights
novatec
Cathy Tanimura


O'REILLY
Terceira Edição
Python para Análise de Dados
Tratamento de dados com pandas, NumPy e Jupyter
powered by jupyter
novatec
Wes McKinney

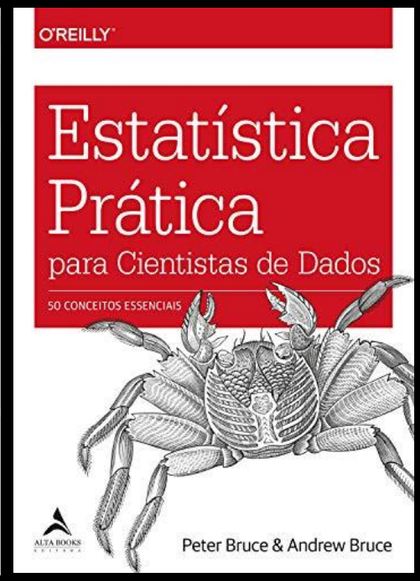
O'REILLY
Estatística Prática
para Cientistas de Dados
50 CONCEITOS ESSENCIAIS
ALTA BOOKS EDITORA
Peter Bruce & Andrew Bruce

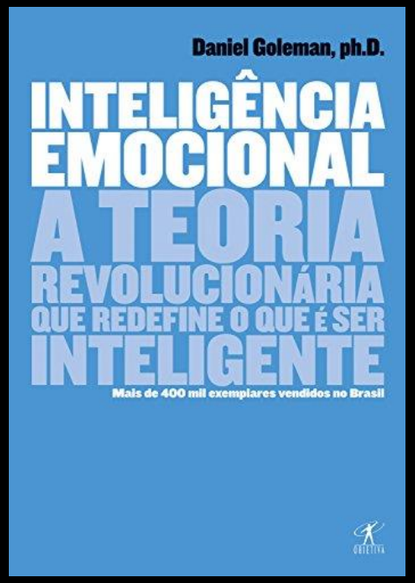
Daniel Goleman, ph.D.
INTELIGÊNCIA EMOCIONAL
A TEORIA REVOLUCIONÁRIA QUE REDEFINE O QUE É SER INTELIGENTE
Mais de 400 mil exemplares vendidos no Brasil
OBJETIVA

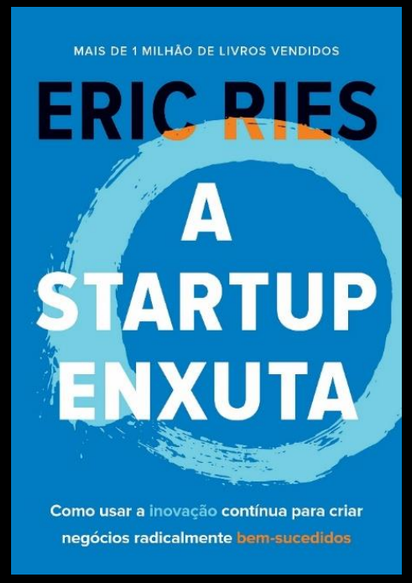
MAIS DE 1 MILHÃO DE LIVROS VENDIDOS
ERIC RIES
A STARTUP ENXUTA
Como usar a inovação contínua para criar negócios radicalmente bem-sucedidos

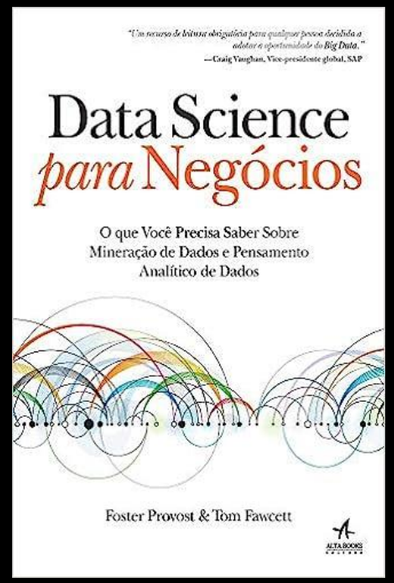
"Um recurso de leitura obrigatória para qualquer pessoa decidida a adotar a oportunidade do Big Data."
—Craig Vaughan, Vice-presidente global, SAP
Data Science para Negócios
O que Você Precisa Saber Sobre Mineração de Dados e Pensamento Analítico de Dados
Foster Provost & Tom Fawcett
ALTA BOOKS EDITORA

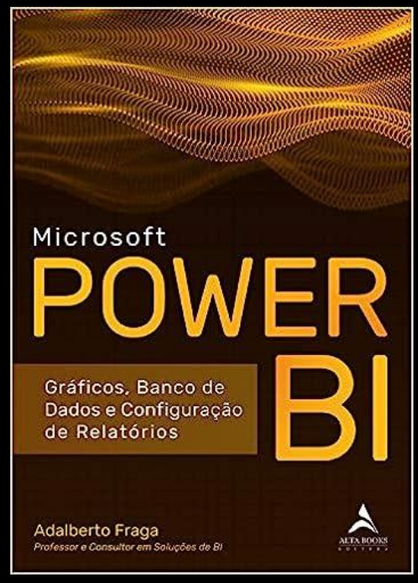
Microsoft
POWER BI
Gráficos, Banco de Dados e Configuração de Relatórios
Adalberto Fraga
Professor e Consultor em Soluções de BI
ALTA BOOKS EDITORA

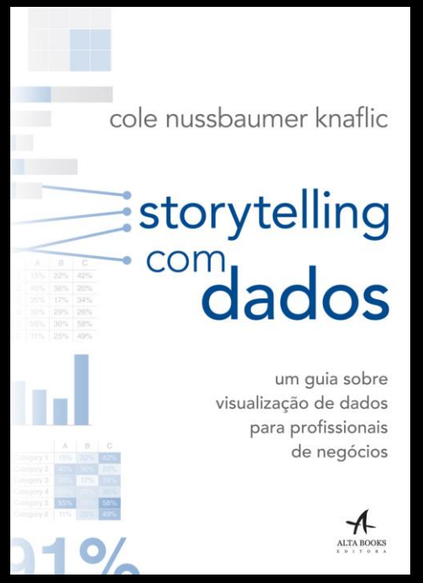
cole nussbaumer knaflic
storytelling com dados
um guia sobre visualização de dados para profissionais de negócios
ALTA BOOKS EDITORA

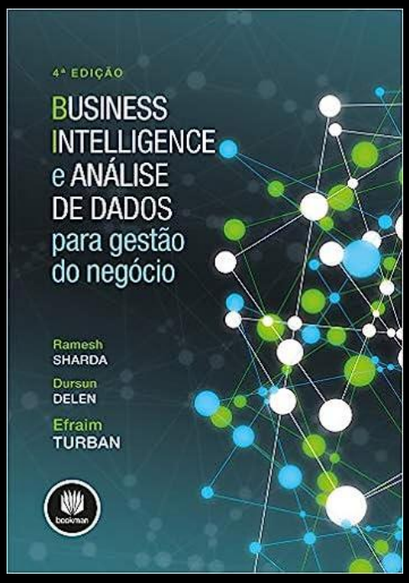
4ª EDIÇÃO
BUSINESS INTELLIGENCE e ANÁLISE DE DADOS para gestão do negócio
Ramesh SHARDA
Dursun DELEN
Efraim TURBAN
bookman

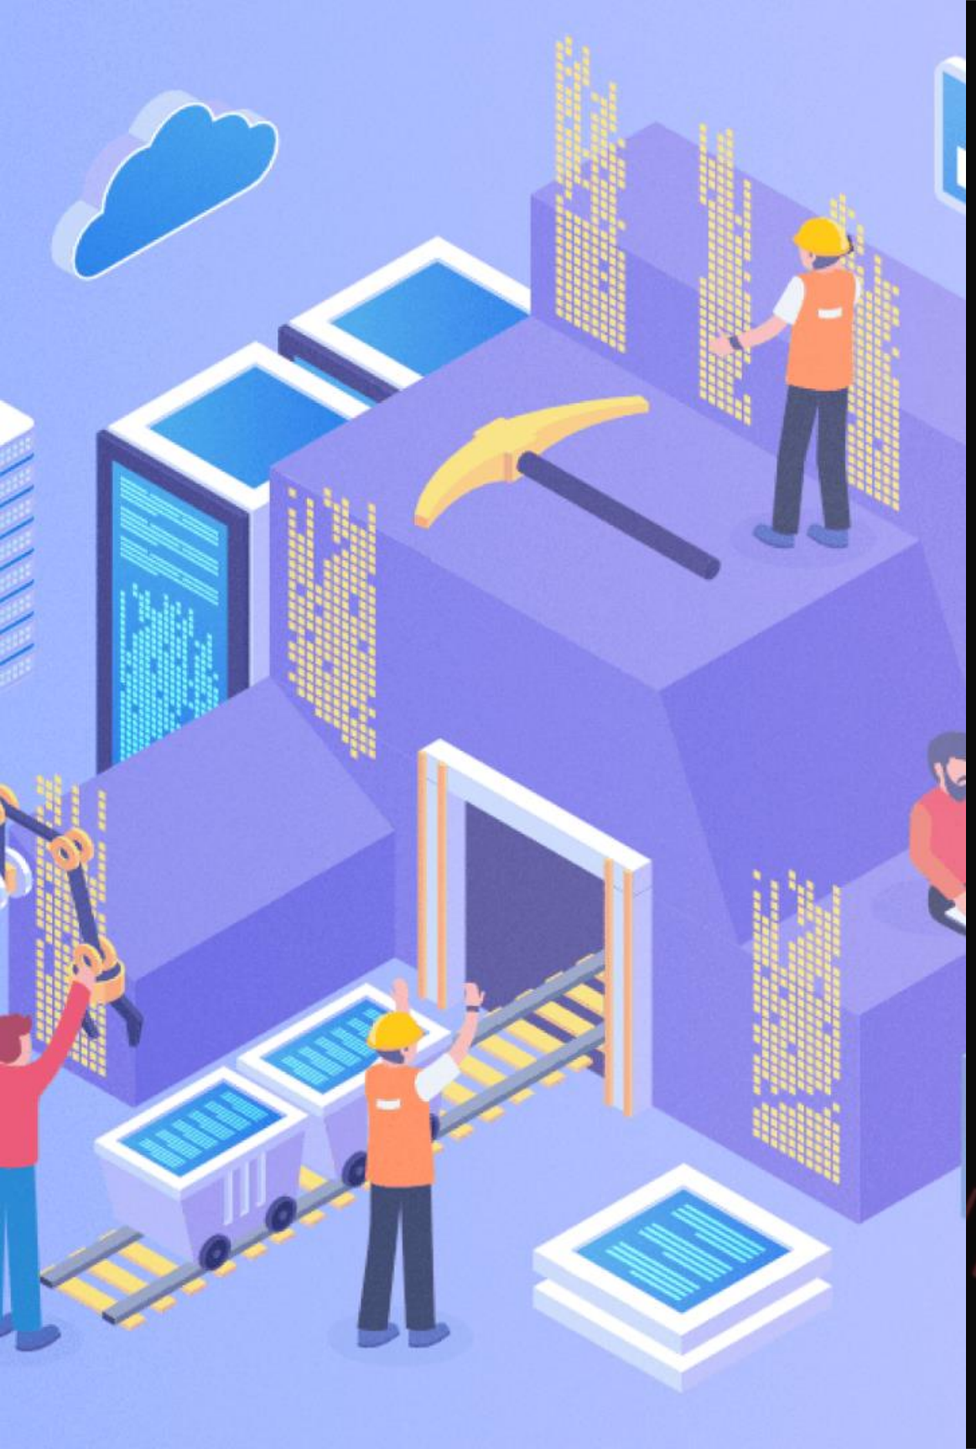

Descoberta de Conhecimento em Bancos de Dados (KDD)

KDD - *Knowledge Discovery in Databases* (Descoberta de Conhecimento em Bancos de Dados) é um processo que envolve **seleção**, **pré-processamento**, **transformação** e mineração de dados, avaliação de padrões, apresentação de resultados e utilização do conhecimento. Essa técnica ajuda a extrair informações úteis e valiosas de grandes quantidades de dados.

Introdução ao KDD

Por que KDD?

Grandes quantidades de dados são gerados todos os dias, mas o acesso a informação valiosa é difícil devido ao volume.

Como funciona?

O processo de KDD envolve diversas etapas que começam com a seleção de dados e terminam com a utilização do conhecimento adquirido.

Benefícios

O KDD permite a descoberta de informações e padrões ocultos em grandes quantidades de dados, possibilitando melhores decisões e descobertas.

Etapas do processo de KDD

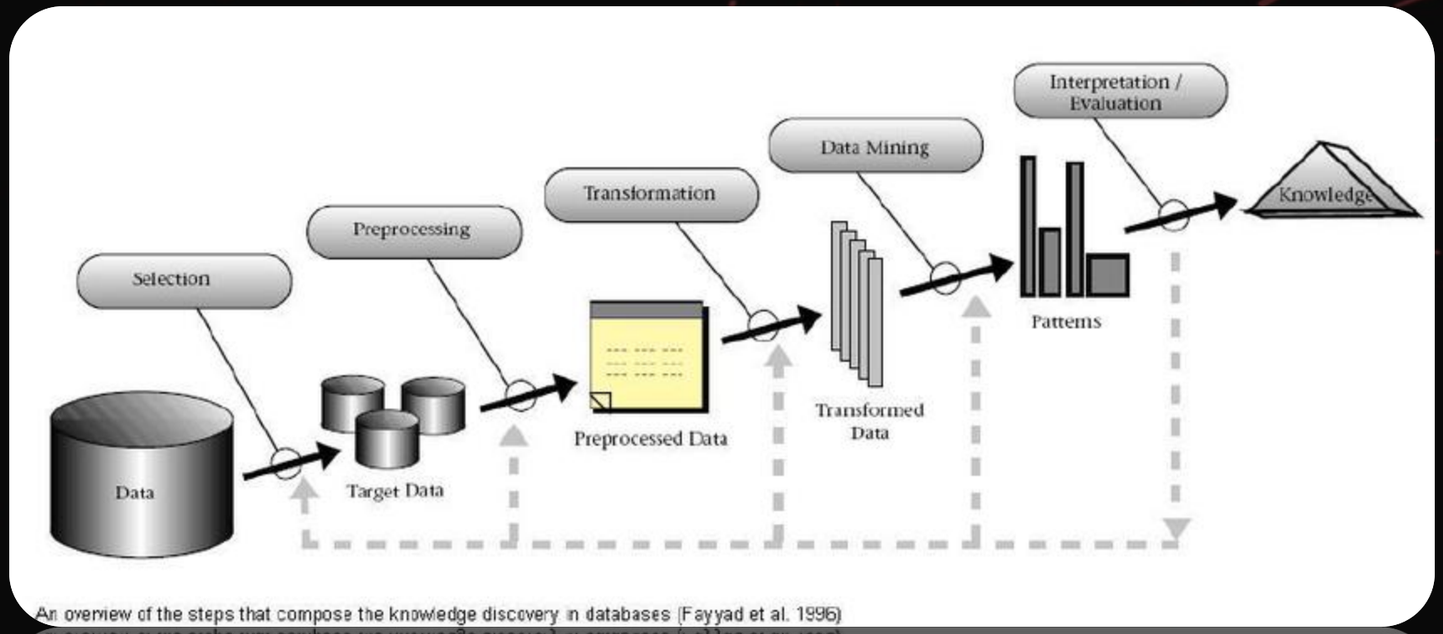

An overview of the steps that compose the knowledge discovery in databases (Fayyad et al. 1996)

Seleção de dados

Seleção manual

Selecionar manualmente os dados que são relevantes para a análise.

Utilização de filtros

Utilizar filtros para selecionar os dados que são relevantes para análise.

Amostragem

Selecionar uma amostra representativa dos dados para análise.

Dados completos

Analisar a totalidade dos dados disponíveis.

Pré-processamento de dados

Transformação e Enriquecimento de dados

Converter dados em **formatos** adequados e **limpos**, **corrigir** os **valores** que estiverem errados. **Enriquecer** dados.

Limpeza de dados

Remover dados **inconsistentes**, **duplicados** e **irrelevantes**.

Redução de dados

Tornar os dados mais compactos sem perder informações, agrupando-os em classes ou selecionando características-chave.

Complementar valores

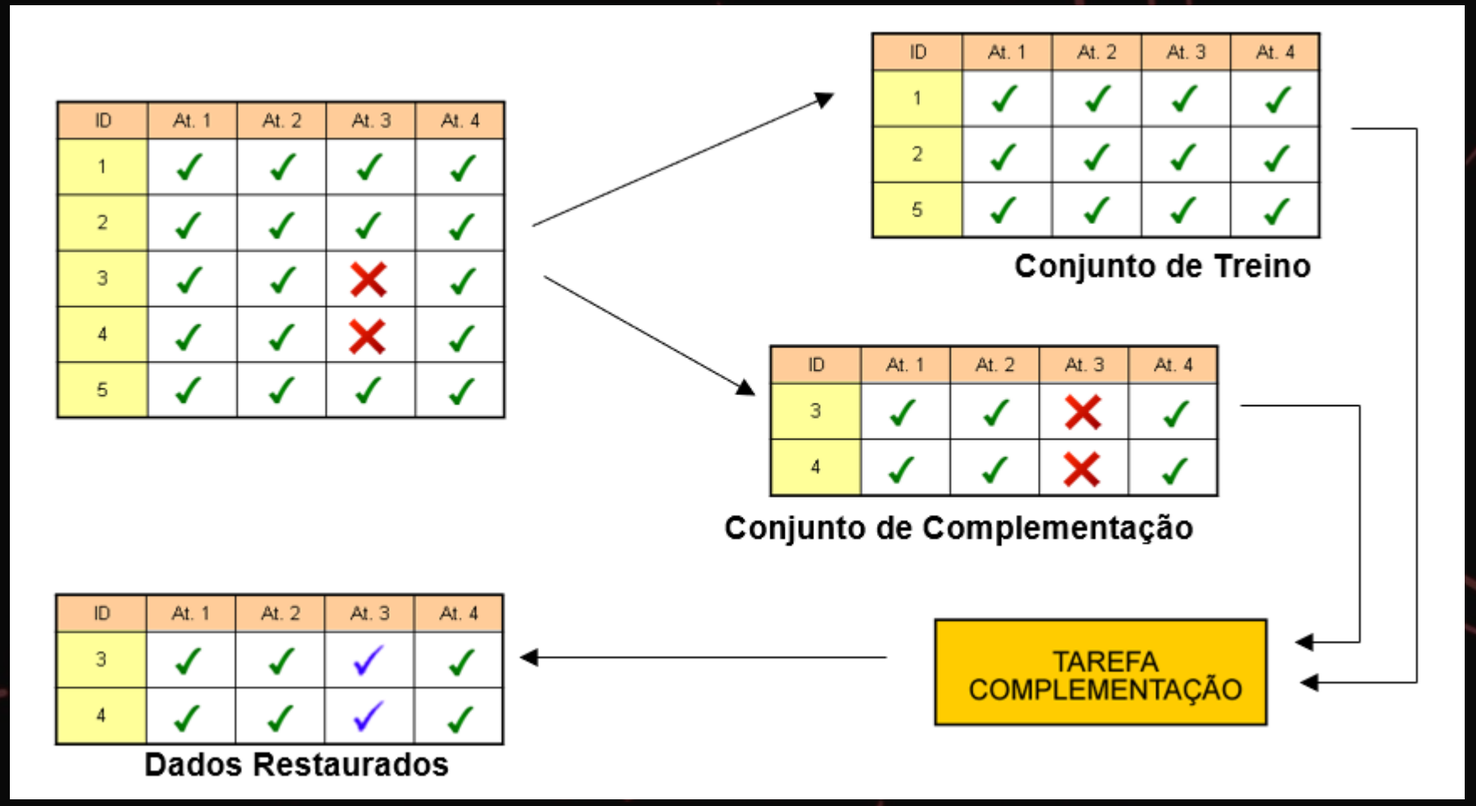

Transformação de Dados

1 **Normalização**

Transformar os valores dos dados para uma escala comum.

2 **Discretização**

Converter dados contínuos em dados discretos.

3 **Agregação de dados**

Agrupar dados em categorias ou grupos.

4 **Redução de dados**

Reduzir a dimensionalidade dos dados mantendo sua importância.

Data Mining

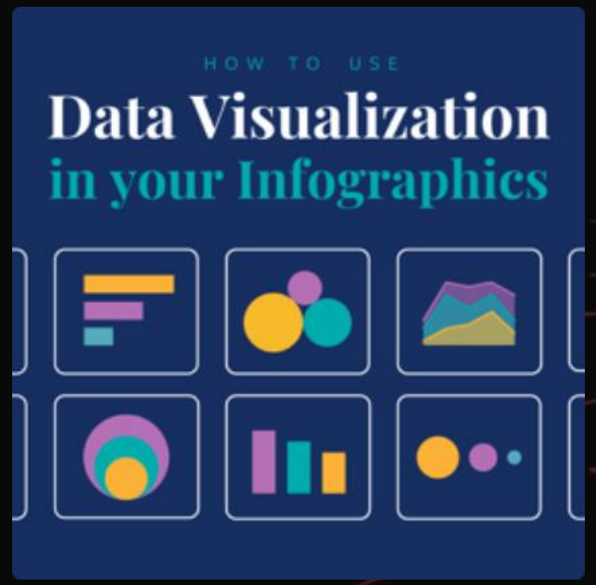

Visualização de Dados

Gráficos e mapas para ajudar a ver tendências e padrões nos dados.

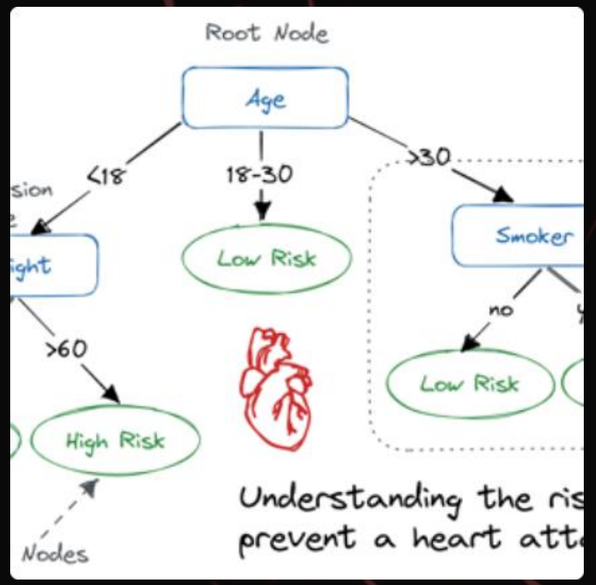

Árvores de Decisão

Um modelo para ajudar na identificação de padrões e tendências

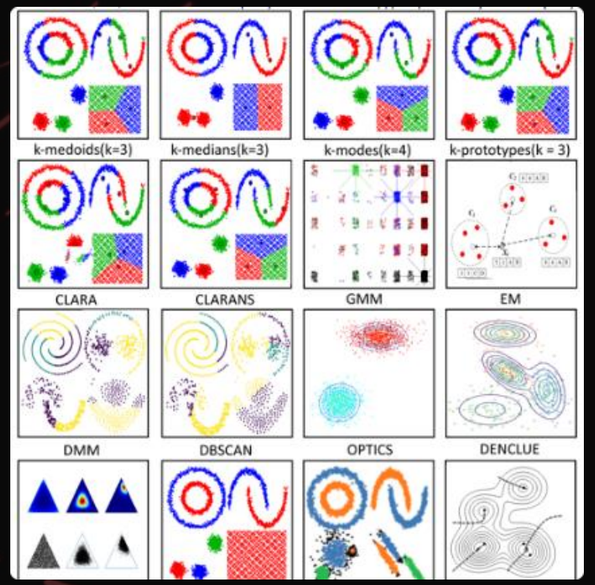

Clustering

Agrupamento de dados em conjuntos com base nas suas características comuns.

Avaliação de Padrões

Seleção de Padrões

Selecionar padrões com base no seu interesse.

Avaliação de Padrões

Verificar a validade dos padrões identificados de acordo com critérios predefinidos.

Interpretação

Compreender o significado dos padrões descobertos.

Apresentação de Resultados

1

Relatórios

Incluir estatísticas, tabelas, gráficos e outros recursos visuais.

2

Visualização de Dados

Gráficos e mapas para ajudar a ver tendências e padrões nos dados.

3

Interpretação

Apresentar o significado e as implicações dos padrões identificados.

Utilização do Conhecimento

Máquina vs Humano

Com a ajuda de ferramentas de KDD, máquinas podem tomar decisões mais precisas e rápidas do que humanos.

Exemplo

Analisar dados do histórico de compras dos clientes para desenvolver ofertas personalizadas e antecipar as necessidades do cliente.

Mais exemplos

Analisar dados médicos para identificar doenças em estágio inicial e desenvolver novos protocolos de tratamento

Considerações

Ferramentas

O processo de KDD ganhou impulso devido à disponibilidade de ferramentas sofisticadas, como Data Warehouses, Hadoop e SAS.

Avanços

A tecnologia continua avançando, permitindo a coleta e análise de dados mais precisos em uma escala ainda maior.

Potencial

O potencial da Descoberta de Conhecimento em Bancos de Dados ainda não foi completamente explorado. Novas aplicações continuam surgindo todos os dias.

Obrigado!

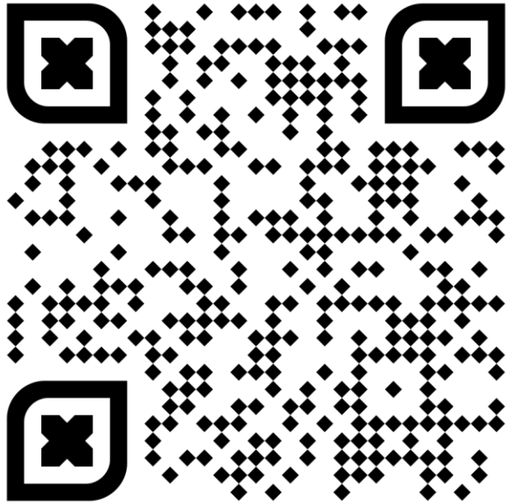

CRISP-DM: Descobrindo Conhecimentos em Dados

O **CRISP-DM** (*Cross Industry Standard Process for Data Mining*) é uma metodologia de mineração de dados amplamente utilizada. Isso permite que as organizações obtenham insights valiosos a partir de seus dados. Aprenda como implementar esta metodologia e alcance insights importantes.

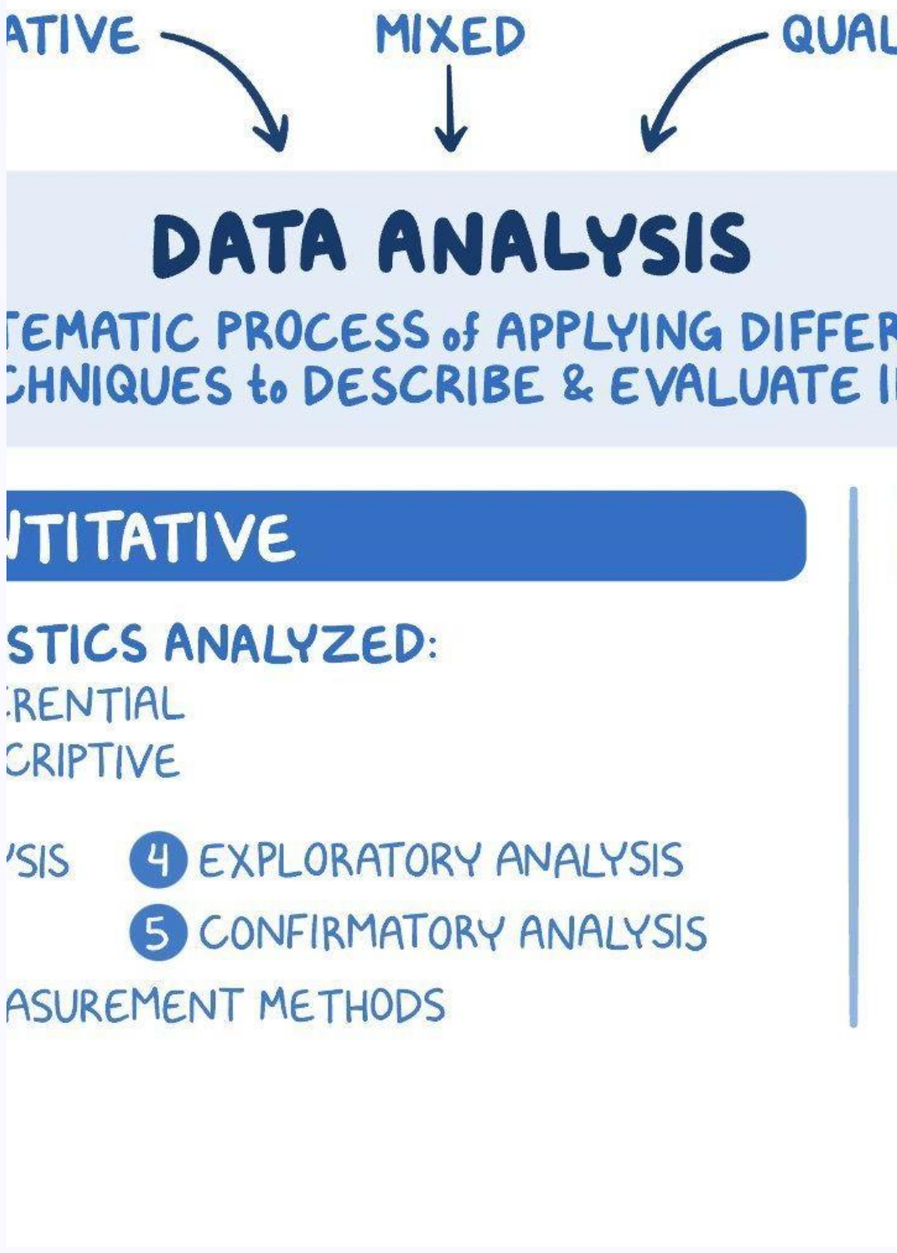

Introdução ao CRISP-DM

1

O que é o CRISP-DM?

O CRISP-DM é uma metodologia utilizada para mineração e análise de dados. Ele é frequentemente usado para ajudar as empresas a identificar insights valiosos em seus dados.

2

Qual a sua origem?

O CRISP-DM foi criado em 1996 por um consórcio composto por várias empresas líderes em mineração de dados. Tornou-se uma estrutura amplamente aceita para mineração de dados empresarial.

3

Pra que serve?

O CRISP-DM permite uma abordagem sistemática para mineração de dados, ajudando as organizações a alcançar insights valiosos de seus dados de maneira consistente e repetível.

CRISP-DM


Business Understanding
Data Understanding
Data Preparation
Modeling
Evaluation
Deployment
Data

Fases do CRISP-DM

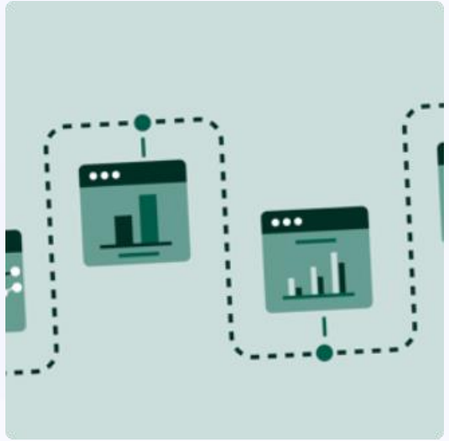

Entendimento do Negócio

Os objetivos do projeto são definidos, analisando-se as metas da empresa, determinando as principais perguntas de negócios a serem respondidas.

Entendimento dos Dados

Os dados relevantes para o projeto são identificados, coletados, integrados e selecionados para posterior análise.

Preparação dos Dados

O conjunto de dados é preparado para a mineração de dados, limpo, traduzido e transformado em um formato aceitável para a análise.

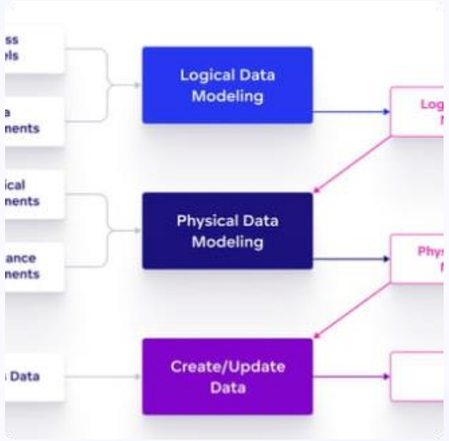

Modelagem

O modelo final é selecionado para auxiliar a realização do objetivo de negócios pré-determinado.

Avaliação e Implantação

1

Avaliação

O modelo construído é avaliado e revisado quanto à sua precisão e eficácia.

2

Implantando um Modelo

O modelo implantado é monitorado e mantido para garantir que ele continue a atender às necessidades de negócios em mudança.

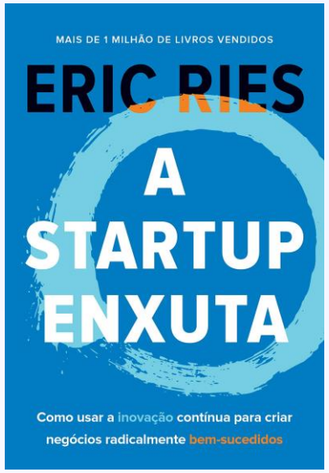

Exemplos e casos de uso do CRISP-DM

Vendas e Marketing

Pode ser usado para ajudar a identificar clientes de alto valor e segmentá-los em grupos com base em sua probabilidade de compra..

Previsão do Tempo

O CRISP-DM pode ser aplicado para prever o clima futuro, com base em dados históricos e em tempo real.

Melhorias de Processo

Pode ser usado para identificar áreas para melhorias de processos em empresas, procurando por padrões e anomalias em dados operacionais.

Conclusão

Ferramentas padrão, como a metodologia CRISP-DM, podem ser usadas para enfatizar a importância do gerenciamento de dados nas organizações e trazer benefícios reais e tangíveis, incluindo aumento da eficiência, compreensão do público alvo, previsão de demanda, detecção de fraudes e muito mais.

Obrigado!

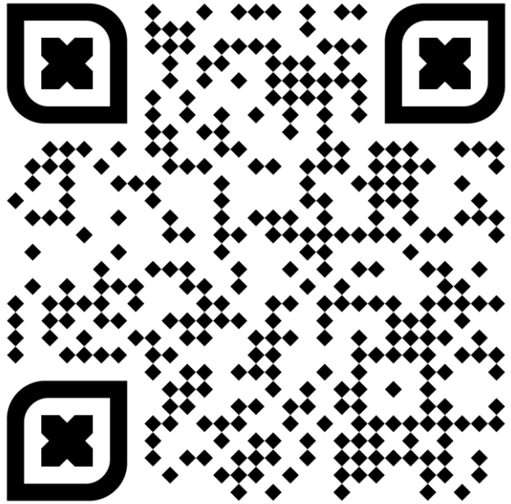

ETL - Extract Transform Load

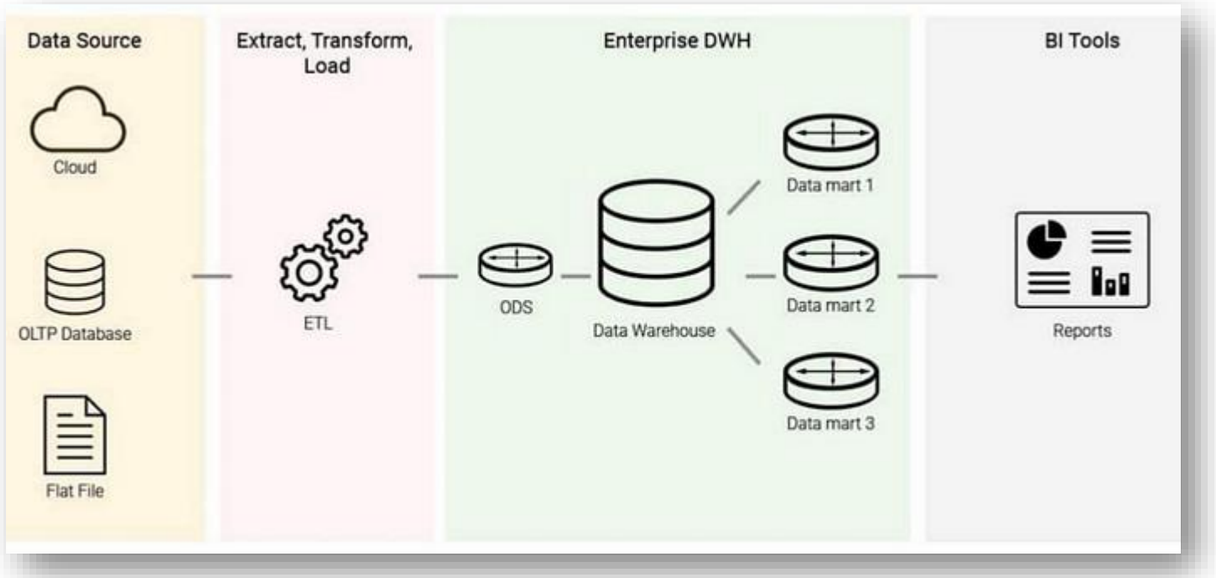

ETL - Extract Transform Load

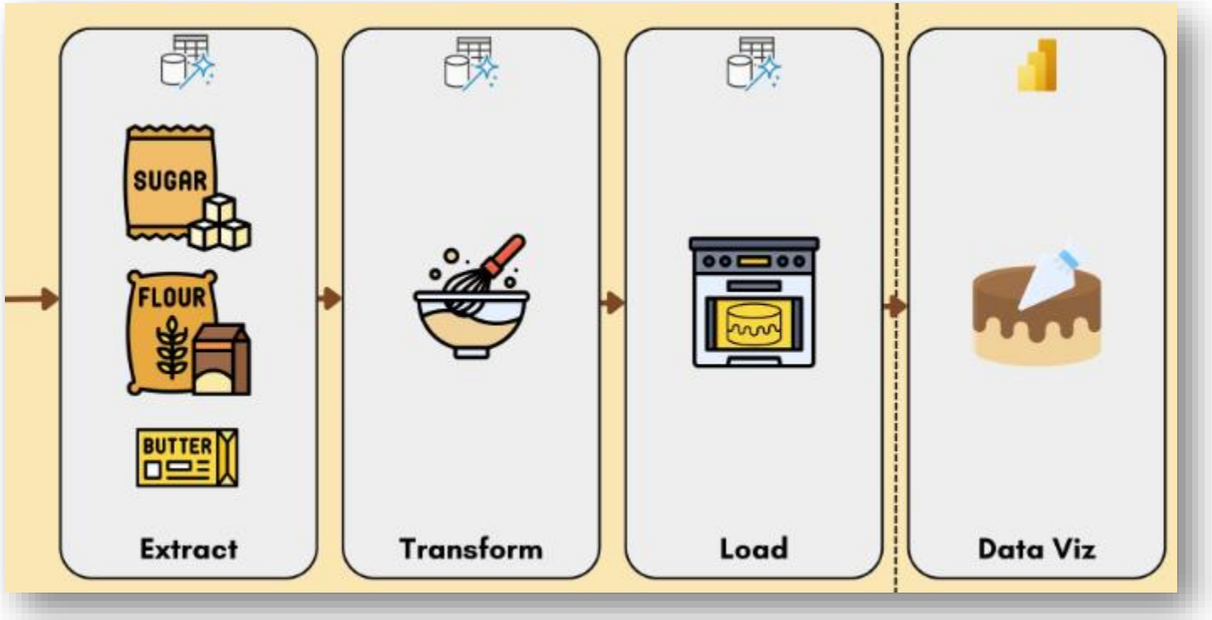

Desenho da arquitetura atual

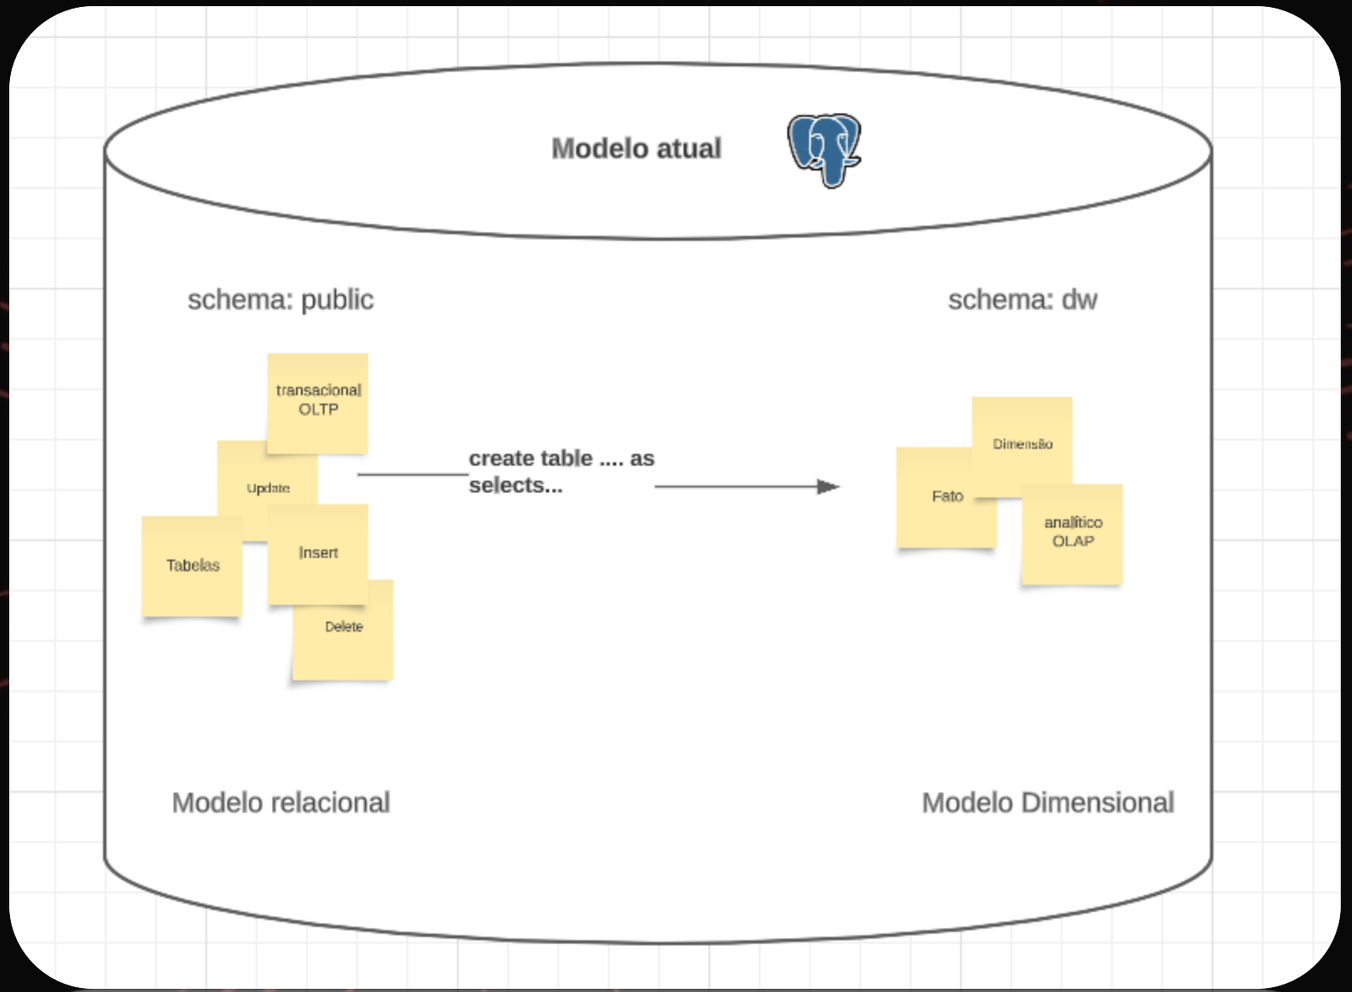
Modelo atual
schema: public
schema: dw
transacional
OLTP
Update
Tabelas
Insert
Delete
create table .... as
selects...
Dimensão
Fato
analítico
OLAP
Modelo relacional
Modelo Dimensional

Lucidchart

Desenho da arquitetura ideal

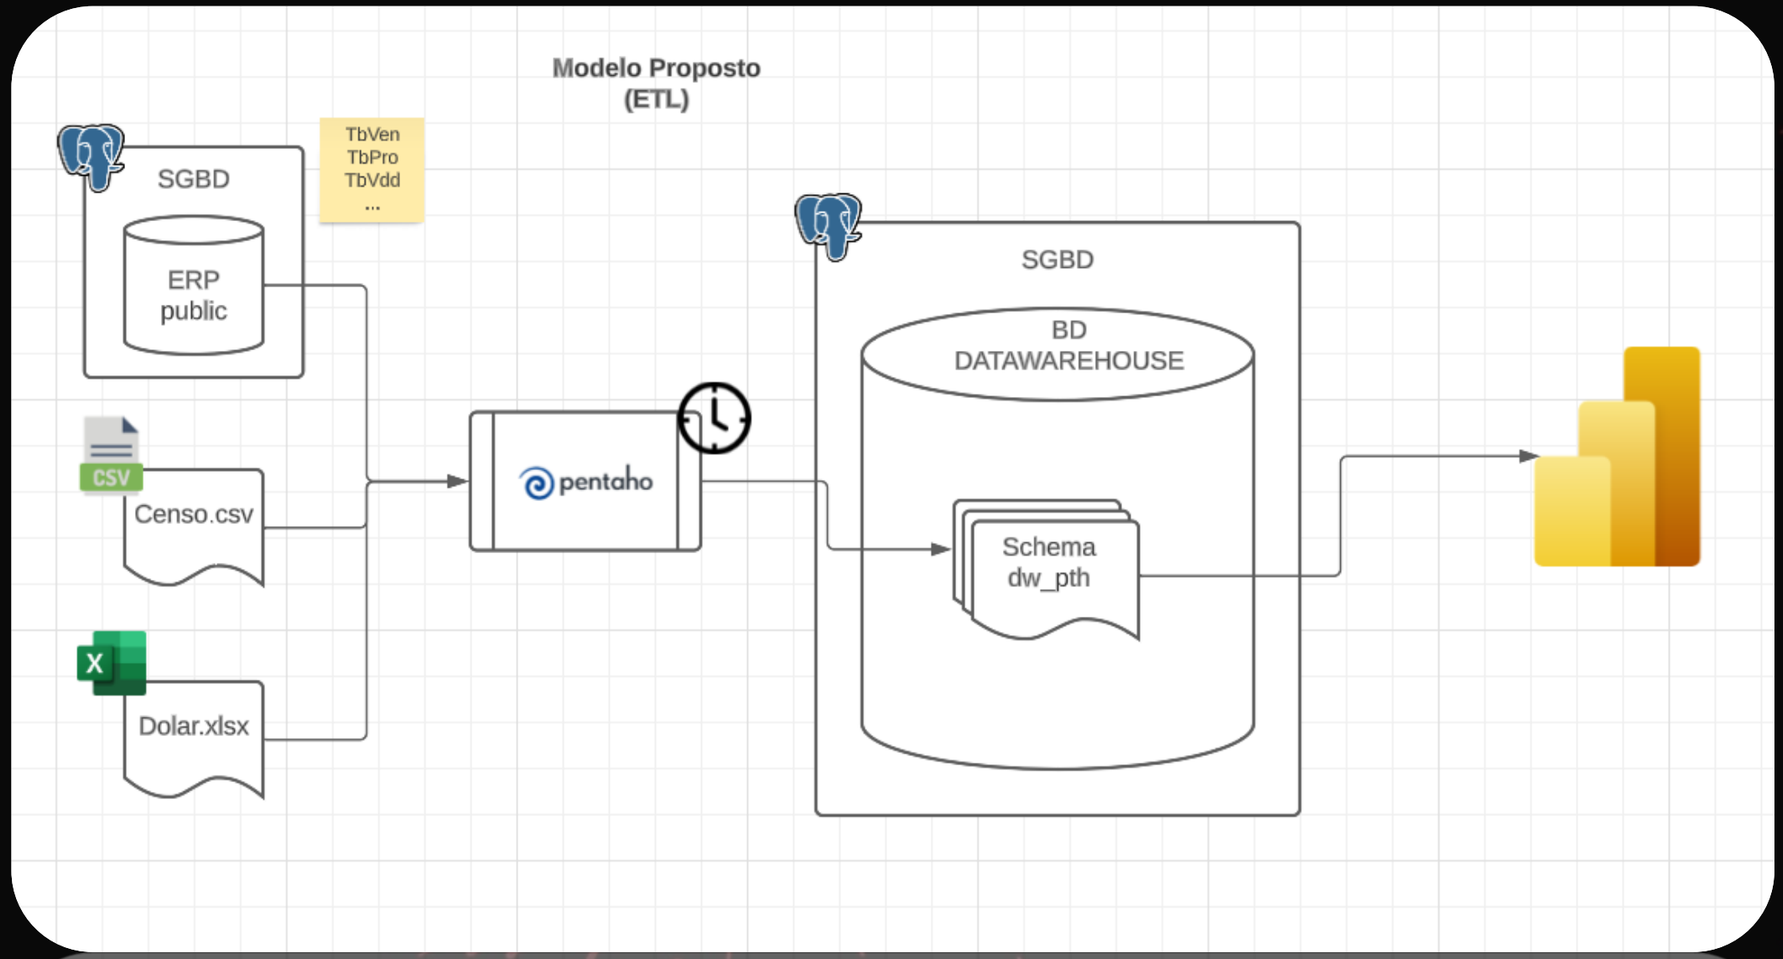
Modelo Proposto
(ETL)
SGBD
ERP
public
TbVen
TbPro
TbVdd
...
CSV
Censo.csv
X
Dolar.xlsx
pentaho
SGBD
BD
DATAWAREHOUSE
Schema
dw_pth

Lucidchart

Pentaho ETL: Uma Explanação Completa

A extração, transformação e carregamento (ETL) de dados são cruciais para o funcionamento efetivo de empresas.

Com o Pentaho Data Integration, você pode gerenciar seus dados de maneira eficiente e confiável, economizando tempo e recursos valiosos.

Introdução à Ferramenta de ETL

O que é o Pentaho ETL

Uma ferramenta de ETL de última geração usada para integrar e transformar dados de diferentes fontes em soluções empresariais.

Por que usar o Pentaho ETL?

Garante a qualidade dos dados, aumenta a eficiência do negócio e, consequentemente, o lucro da empresa.

Vantagem competitiva

O Pentaho ETL ajuda a manter a empresa à frente da competição, fornecendo dados precisos e em tempo real.

Funcionalidades da Ferramenta Pentaho

1

Conexão fácil com várias fontes de dados

Integra-se facilmente com bancos de dados, aplicativos e serviços, além de permitir o acesso a diferentes arquivos.

2

Tarefas agendadas

A execução de ETL pode ser agendada para que ocorra em horários determinados, sem a intervenção do usuário.

3

Transformações completas

O Pentaho ETL oferece várias opções de transformação de dados, garantindo que todos os dados de fontes diferentes sejam usados de forma coesa.

4

Visualização gráfica de transformações e fluxos de dados

A ferramenta permite visualizar as alterações de dados e fluxos de trabalho, tornando mais fácil a compreensão de processos complexos.

Arquitetura do Pentaho Data Integration (PDI)

Arquitetura orientada a plugins

O Pentaho ETL é baseado no conceito de plugins, tornando a arquitetura escalável e adaptável às necessidades do usuário.

Trabalho em conjunto com outras tecnologias

O PDI trabalha bem ao lado de outras tecnologias, oferecendo ainda mais possibilidades para a empresa.

Segurança

O Pentaho ETL possui várias medidas de segurança que garantem a privacidade e integridade dos dados.

Armazenamento de metadados

Armazena todos os metadados relacionados às fontes de dados em um servidor de metadados, facilitando o gerenciamento e localização de informações importantes.

Conexão com Fontes de Dados

1 Fontes de dados compatíveis

O Pentaho ETL pode se conectar a uma variedade de fontes de dados, como bancos de dados, arquivos, serviços da web e aplicativos empresariais.

2 Integração de diferentes tecnologias

Possibilita a integração de bancos de dados e tecnologias diferentes.

3 Maior eficiência do negócio

Elimina a necessidade de criar um código personalizado de conexão de dados, o que aumenta a eficiência do negócio.

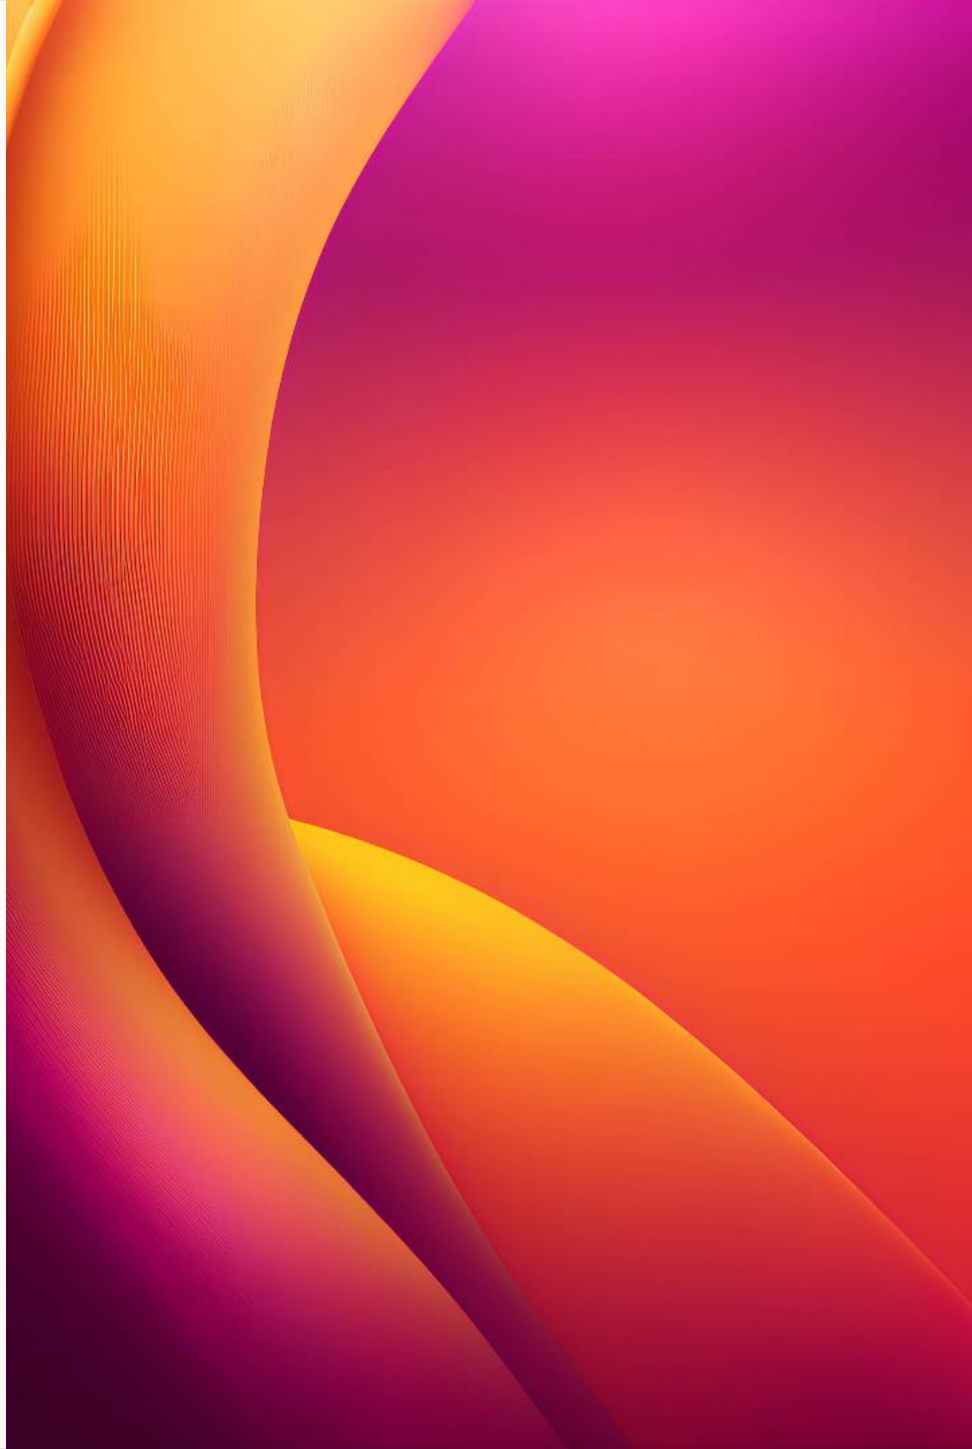

Transformação de Dados com Pentaho Data Integration

Transformação de dados

A transformação de dados pode ser feita de várias maneiras diferentes.

1

Mapa de campo de entrada

O PDI mapeia campos e definições de tabelas de origem.

2

3

Alterações de campos

É possível fazer alterações de campo de acordo com o que se deseja obter e produzir.

Job

O que é Job

É uma maneira de chamar e executar transformações de dados no Pentaho ETL.

Funcionamento do Job

A execução de um Job pode ser acionada por **tempo**, **eventos** ou por outros Jobs e transformações.

Importância do Job

O Job é importante para garantir que as transformações de dados sejam feitas corretamente e em um tempo apropriado.

Diferença entre Transformação e Job

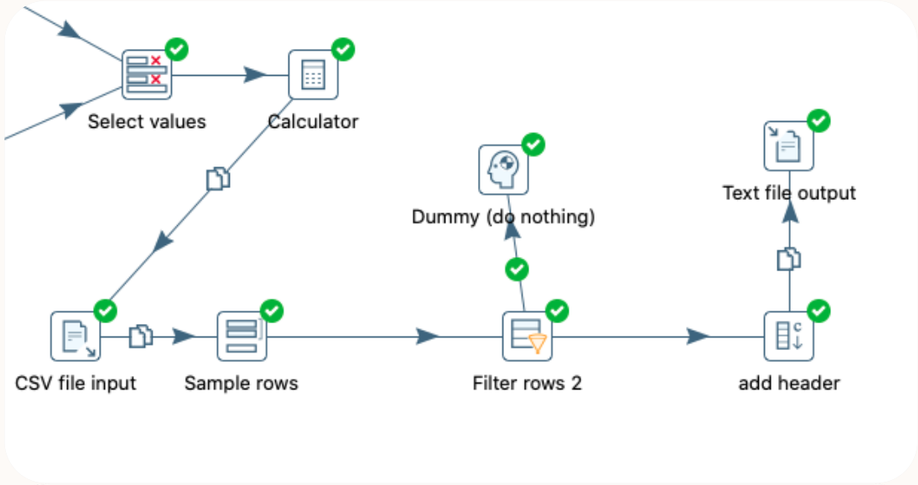

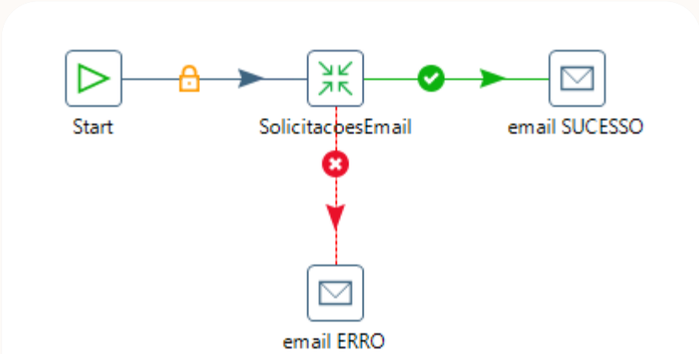

Transformação

Transforma um conjunto de dados por meio da aplicação de diversas regras de negócio ou lógicas.

Job

Coordena as transformações de dados e pode ser **programado para ser executado** em horários específicos.

Exportando dados de um arquivo Excel para um banco de dados PostgreSQL

Passos para exportação

Criar uma conexão com o banco de dados, selecionar o arquivo Excel de origem e, em seguida, mapear as colunas de origem e destino.

Dados de origem

Todos os dados de origem precisam estar em formato tabular para serem colocados em um banco de dados.

Dados de destino

Após a conexão com o banco de dados estabelecida, os dados podem ser exportados em tempo real ou programados para serem exportados periodicamente.

Principais Benefícios da Utilização do Pentaho Data Integration

Garantia de Dados Precisos

- Transformação confiável e segura dos dados
- Padronização dos dados para garantir a qualidade
- Automação de etapas do processo de ETL, evitando possíveis erros humanos.

Fluxos de Trabalho Eficientes

- Aceleração do processo de ETL
- Uso de técnicas para otimização de desempenho
- Utilização de recursos e ferramentas para maximização da produtividade

Redução dos Custos

- Eliminação de customização de código carro-chefe para a conexão de dados
- Maior produtividade
- Redução significativa do tempo de desenvolvimento do ETL

Instalação do Pentaho

pentaho®
A Hitachi Group Company

Primeiros passos no Pentaho

pentaho®
A Hitachi Group Company

pentaho
A Hitachi Group Company

A Odisseia da Empresa Z em busca de Análises Otimizadas

Marketing

Locação Veículos

ERP

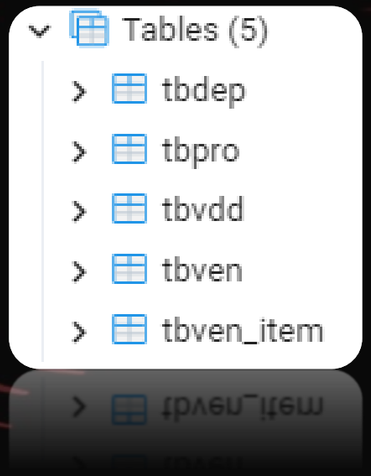

Obrigado!

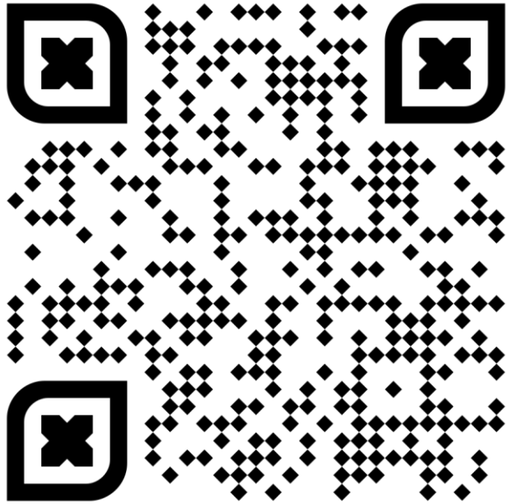

Obrigad@!

Digital College

ENSINO DE HABILIDADES DIGITAIS

digitalcollege.com.br • @digitalcollegebr